2024Examen-1-Parcial-Solucions-M...

alucero

Visualització de Dades

3º Grado en Ingeniería de Datos

Escuela de Ingeniería
Universidad Autónoma de Barcelona

Visualització de dades (Enginyeria de Dades – EE - UAB)
Examen Primer Parcial – 08 Abril 2024
SOLUCIONS MODEL 1

Nom i Cognom:_____

NIU:_____ Grup de Matrícula:_____

PARTE 1 (3.5 pt)

Dataset: titanic.csv

1.1. (0.5 pt) Abre el fichero. ¿Qué tipo de atributo son: ***Survived, Pclass, Sex, Age***, y ***Fare***? ¿Qué atributo es el key (clave primaria) del dataset?

RESPOSTA:

Survived=Categórico, Pclass=Ordinal, Sex=categórico, Age=Cuantitativo, Fare=Cuantitativo. El key es PassengerID

1.2. (1 pt) Haz una gráfica que muestre **en qué clase** (Pclass) hubo más sobrevivientes. Sube la gráfica y el código.

RESPOSTA:

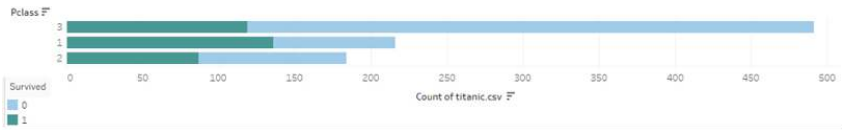

1.3 (2 pt) Queremos saber si la clase en la que viajaban los pasajeros (Pclass) influye en la **probabilidad** de sobrevivir (***Survived***). Haz una gráfica que permita visualizar esa relación y razona tu elección de acuerdo al framework Datos/Tareas/Codificación (Cuantos atributos usas y de qué tipo son; qué tarea ayuda a llevar a cabo la gráfica; marcas y canales empleados, etc).

Sube la imagen de la gráfica debidamente anotada junto al código y la respuesta.

RESPOSTA:

Survived y Pclass son de tipo categórico y categórico ordinal. Se puede visualizar como una gráfica de barras agrupadas o apiladas, donde un categórico se utiliza para determinar la posición en el eje horizontal y el otro para separar cada barra en dos secciones de colores distintos. Si se utilizan porcentajes seran barras normalizadas. Las barras normalizadas son mejores porque permiten comparar con más precisión entre clases a pesar de las diferencias en número de pasajeros.

(En R vimos en seminario 2 cómo hacer estos gráficos en R usando: geom_bar(position="dodge")

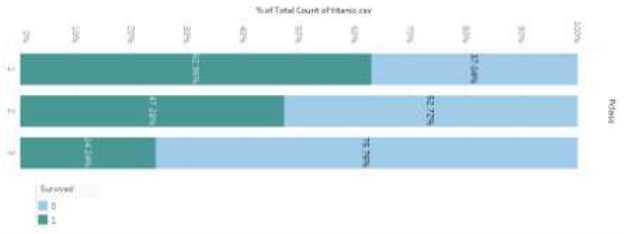

PARTE 2 (1.5 pt)

Dataset: 2017_accidents_vehicles_gu_bcn.csv

El dataset contiene registros de accidentes de tráfico en Barcelona durante 2017, con detalles como el día, hora,

2.1. (1.5 pt) Haz una gráfica que muestre a qué hora del día sucedió el mayor número de accidentes ese año. Razona brevemente el tipo de gráfica elegida y porqué la has usado en este caso en relación al framework Datos/Tareas/ Codificación. Sube la respuesta (0.5pt), la gráfica (0.5pt) y el código (0.5pt).

RESPOSTA:

En este caso se puede hacer un histograma con binSize=1 o una gráfica de barras usando “rep” para tener el conteo de cada valor. Se codifica la frecuancia en el tamaño de las barras y se ordenan por hora, de este modo es fácil ver las horas con mayor número de accidentes y compararlas entre ellas.

```
hour <- df$'Hora_de_dia'
# Histogram of Hour
ggplot(df, aes(x=as.numeric(hour))) +
  geom_histogram(binwidth=1, color="darkblue", fill="lightblue")
# Barplot of Hour
df <- data.frame(x = rep(hour))
ggplot(df, aes(x)) + geom_bar(color="darkblue", fill="lightblue")
```

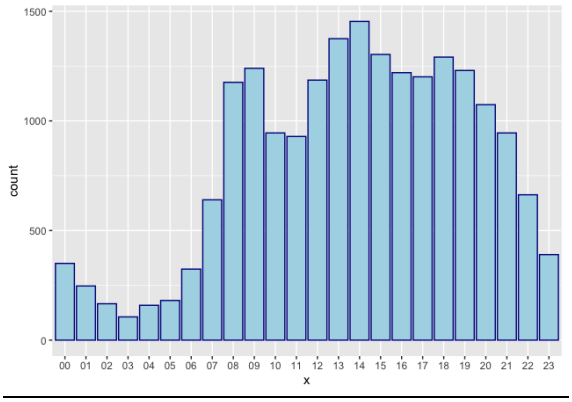

PARTE 3 (5 pt)

Dataframe: simpsons_episodes.csv. Dataset con los detalles de aproximadamente 600 episodios de los Simpson

NOTA: En los ejercicios de esta parte, hacer uso de las *pipes*.

3.1 **(2 pt)** Queremos conocer la relación entre la fecha de emisión original (***original_air_date***) y su respectiva clasificación en Internet Movie Database (***imdb_rating***)

a) Hacer un gráfico que os permita ver la relación entre ambas variables y encontrar algún patrón que se le ajuste. Eliminar valores NAN y/o outliers. (0.75 pt)

b) Hacer una visualización multipanel que os permita analizar cómo varía la relación entre las variables (***original_air_date*** y ***imdb_rating***) a lo largo de las tres primeras temporadas. Para lograr esto, vamos a dividir nuestra visualización en tres paneles, uno para cada temporada ('1', '2', '3'). En cada panel, mostraréis, para cada temporada, la relación entre las variables y ajustaremos el patrón con el intervalo de confianza del 85%. ¿Os aporta algo colorear de un color distinto cada panel o obtenéis la misma información si dejáis los tres paneles sin colorear (razonad la respuesta)? (1.25 pt. Nota: si no se sabe hacer el multipanel mostrar cada gráfico por separado se puntuará 0.75 pt máximo)

RESPOSTA:

a) Carreguem les llibreries tidyverse, dplyr i ggplot2 com sempre. I llegim el fitxer:

```
simpsons <- read_csv('data/simpsons_episodes.csv') #o via el
Environment
```

Abans de trobar el patró fem una gràfica de punts traient els valors nans de les classificacions ('imdb_rating') i fem el scatter plot que ens demanen a l'apartat (a):

```
simpsons %>% drop_na(imdb_rating)%>% ggplot(aes(x=original_air_date,
y=imdb_rating)) +geom_point()
```

Ara provaríem diferent tipus de regressions amb geom_smooth () i canviant 'method'. Però es veu fàcilment amb el gràfic de punts que no s'ajustarà a una regressió lineal, i serà millor un ajust de regressió polinòmica local ('loess' en R) que és també la per defecte de geom_smooth

Finalment posem etiquetes als eixos i títol amb labs, (o amb `xlab` i `ylab`, i un títol amb `ggtitle`) i ajuntem totes les comandes necessàries amb pipes per evitar crear variables temporals. (Això últim s'aplica a tots els exercicis de la part 3)

```
>simpsons %>% drop_na(imdb_rating)%>% ggplot(aes(x=original_air_date,
y=imdb_rating)) +geom_point() + geom_smooth() +labs(title=paste("Els
Simpsons"),x="Any d'emissió original", y="Puntuació")
```

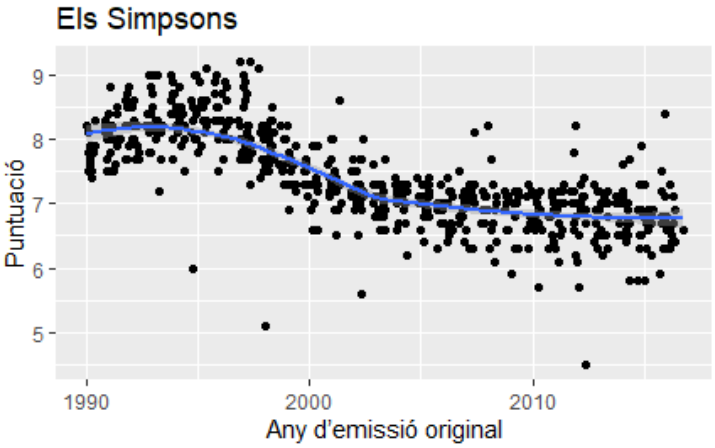

O també:

```
> Simpsons %>% drop_na(imdb_rating)%>% ggplot(aes(x=original_air_date, y=imdb_rating)) +geom_point() + geom_smooth()+xlab('Any d'emissió original')+ylab('Puntuació')+ggtitle('Els Simpsons')
```

B) Molt similar a l'apartat (a), ara però necessitem: i) filtrar les temporades que ens interessen (les tres primeres); ii) posar en ***aes*** el mapeig del color segons la temporada que ens demanen - però tenint en compte que l'escala de color ha de ser discreta assignant un color 'lo suficientment' diferent, i sabem que per això últim necessitem factoritzar 'season' que ara és una variable numèrica contínua amb valors d'1 a 10 ; iii) especificar el % de l'interval de confiança que ens demanen fent us de 'level=0.85' en geom_smooth; iv) fer un ***facet*** on cada fila correspongui a una de les tres temporades, per tant ho fem amb `facet_grid` o `facet_wrap` però especificant-li que volem visualitzar el patró d'una temporada per cada fila, o en un ***facet*** amb sol una columna total:

```
>simpsons%>%filter(season<4)%>%drop_na(imdb_rating)%>%
drop_na(imdb_rating)%>%ggplot(aes(x=original_air_date, y=imdb_rating, color=factor(season))) +geom_point() + geom_smooth(level=0.85) + xlab('Any d'emissió original') + ylab('Puntuació') + facet_grid(season~ .) + ggtitle('Els Simpsons')+ scale_color_discrete(name = "Temporada", labels=c("1", "2", "3"))
```

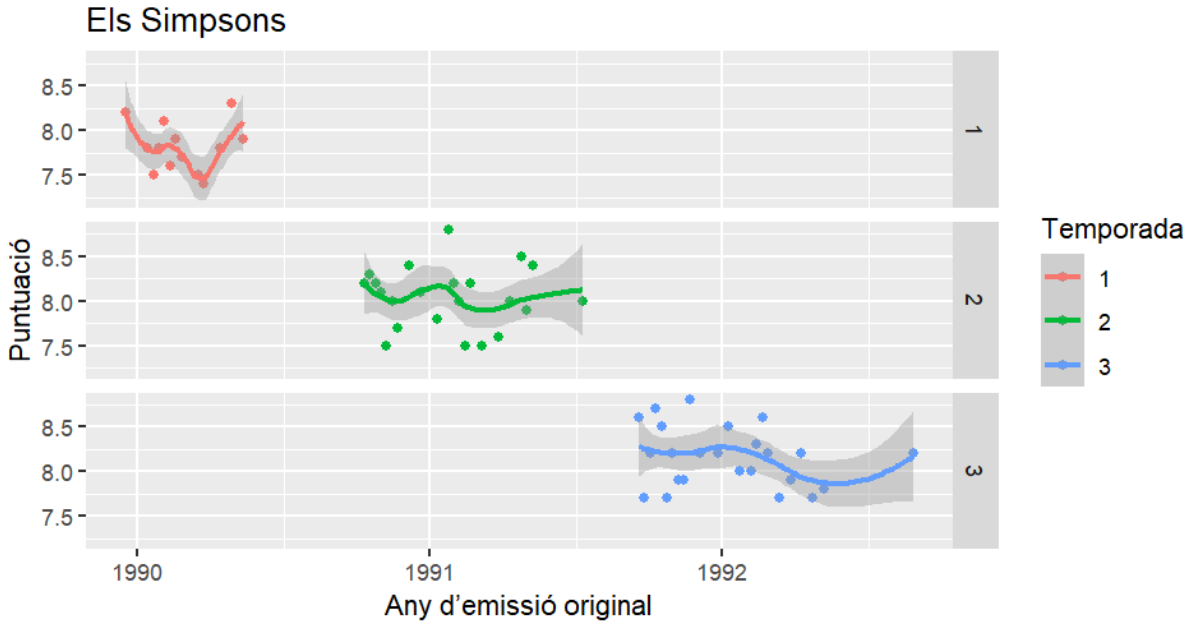

El color no ens aporta informació extra, ja que en cada fila ja hi tenim una temporada

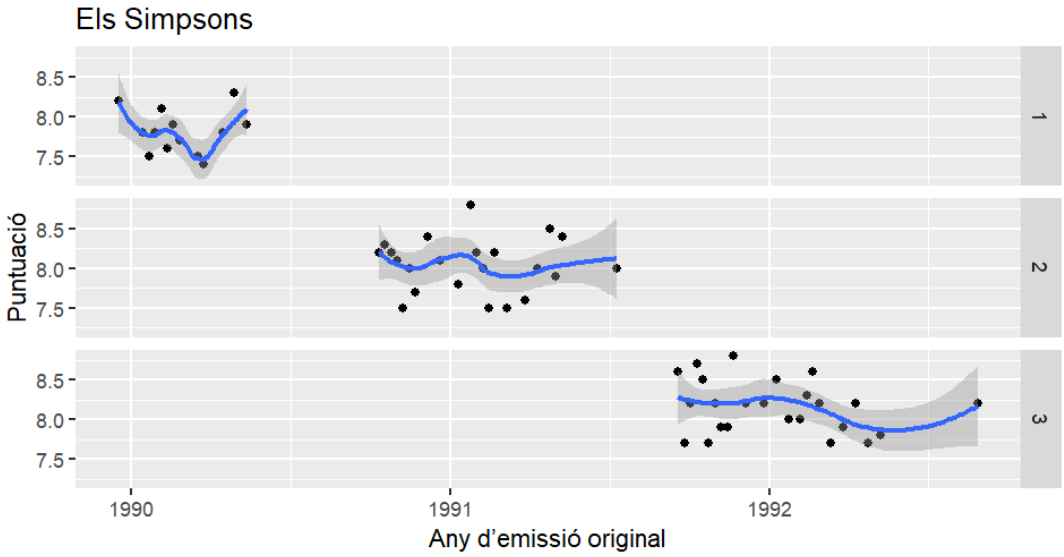

3.2. (1.25 pt) Graficar la distribución de las 10 primeras temporadas ('season') respecto al número de votos ('imdb_votes'). Explicar la elección del gráfico y las conclusiones que podéis extraer del mismo.

```
simpsons%>%filter(season<=10)%>%drop_na(imdb_votes)%>%ggplot(aes(x=factor(season), y=imdb_votes)) +geom_violin() +theme(legend.position='none')+xlab('Temporades')+ylab('Vots')+ggtitle('Visualitzacions de les primeres temporades dels Simpsons')
```

Imagínate aprobando el examen

Necesitas tiempo y concentración

Planes	PLAN TURBO	PLAN PRO	PLAN PRO+
Descargas sin publi al mes	10	40	80
Elimina el video entre descargas	✓	✓	✓
Descarga carpetas	✗	✓	✓
Descarga archivos grandes	✗	✓	✓
Visualiza apuntes online sin publi	✗	✓	✓
Elimina toda la publi web	✗	✗	✓
Precios Anual	0,99 € / mes	3,99 € / mes	7,99 € / mes

Ahora que puedes conseguirlo, ¿Qué nota vas a sacar?

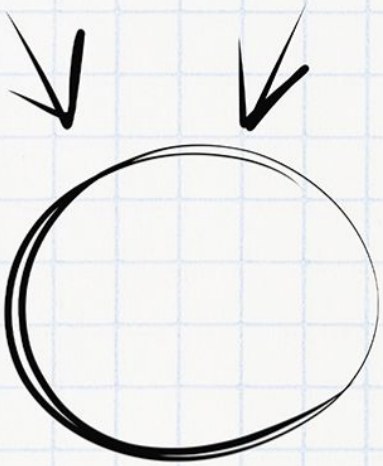

WUOLAH

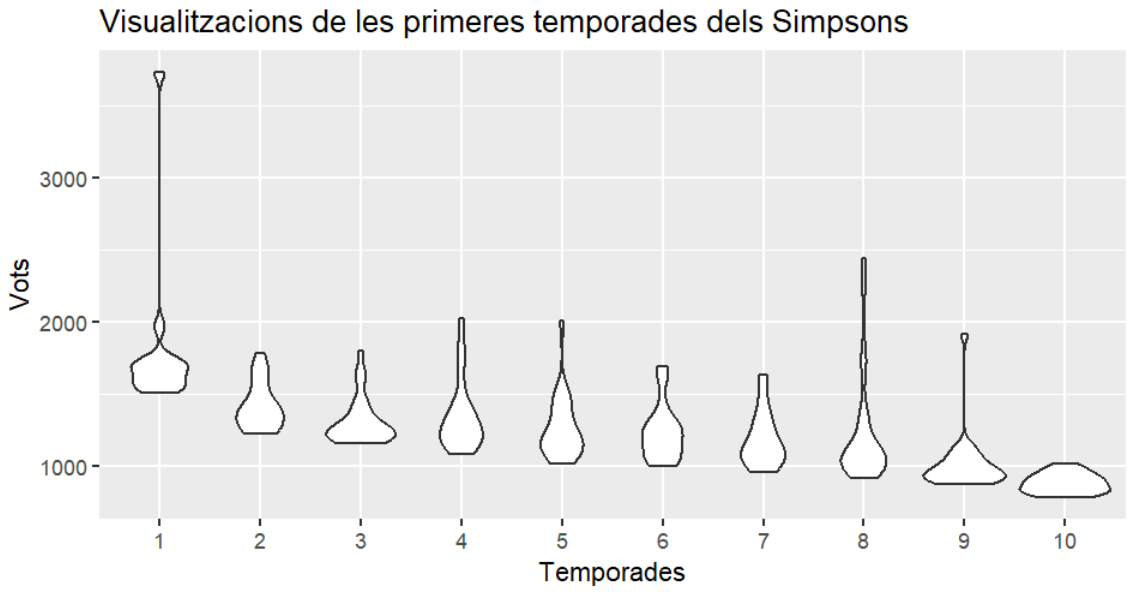

El gràfic ens mostra clarament una davallada de les votacions durant que avancen temporades. A més, els diagrames de violí de les la primera, vuitena i novena temporada tenen cues més llargues, indicant alguns “outliers” de vots. Una altra opció:

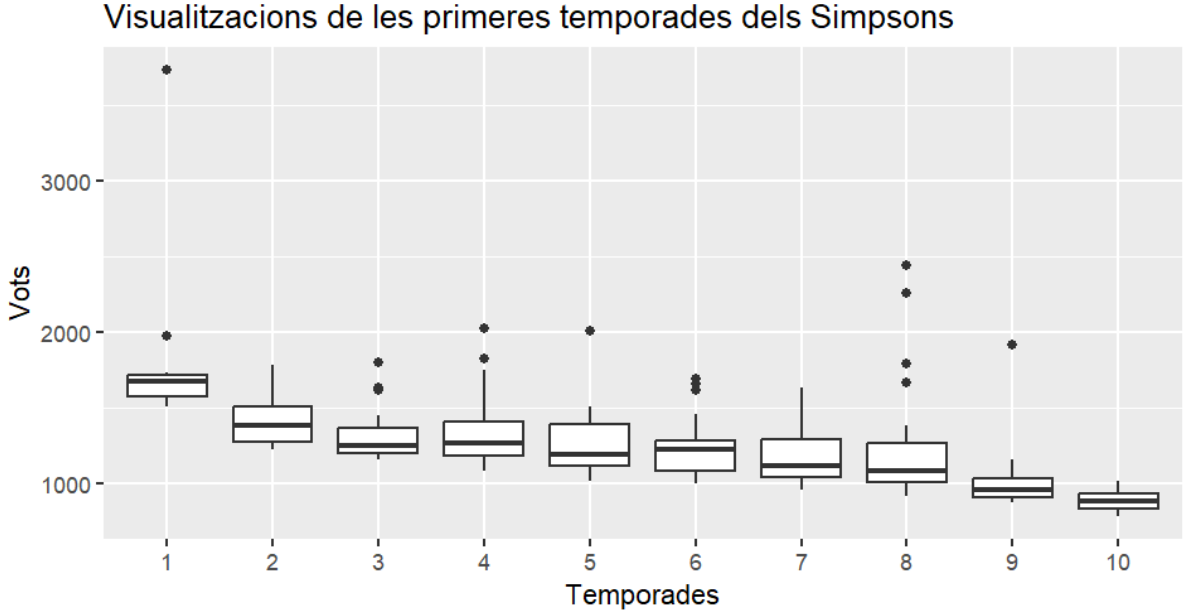

3.3. (1 pt) Graficar la distribución del número de visualizaciones (‘views’) para los episodios en que el nombre de Bart parece en el título (‘tittle’). ¿Cuántos episodios son? Extrae alguna conclusión del gráfico

```
>simpsons%>%
filter(grepl('Bart',title))%>%ggplot(aes(x=views))+geom_density()+
xlab('Visualitzacions')+   ylab('Densitat')   +ggtitle('Visualitzacions
d’episodis on en Bart surt mencionat al títol')
```

Fent el datamassage amb grepl veiem que són 42 episodis

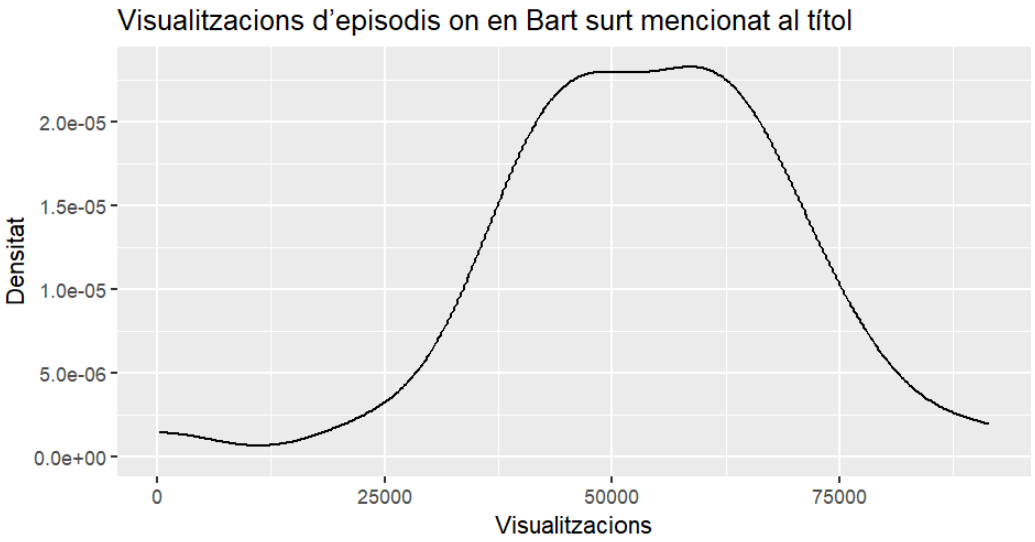

El que es veu clarament aquí és que la major part dels episodis amb la Lisa apareixent en el títol de l'episodi es van veure entre 38000 i 70000 vegades aproximadament, seguint una distribució prou centrada en 55000 visualitzacions. Tot i així cal puntualitzar que amb el filtratge ens hem quedat amb una mostra petita d'episodis (42 episodis)

3.4. (0.75 pt)

Di al menos dos tipos de gráficos que permitan reducir la dimensionalidad (0.25 pt).
Per exemple, LDA i PCA

Imaginemos un conjunto de datos que contiene mediciones biométricas de diferentes especies de plantas, donde las clases representan las diferentes especies. Cada observación tiene múltiples características, como longitud del pétalo, ancho del sépalo, etc. El objetivo es clasificar correctamente las especies de plantas en función de estas características. ¿Qué tipo de visualización sería apropiada para graficar la información sobre las clases de los datos? ¿Sería apropiado si maximizara o minimizara la separación entre las clases mientras reduce la dimensionalidad del conjunto de datos? (0.5 pt).
LDA ens ajudaria a mostrar la informació sobre les classes de les dades, i de fet, maximitzarà la separació entre classes.
Vam veure a classe que:

- L'Anàlisi Discriminant Lineal (LDA) busca separar de la millor manera possible les mostres del conjunt d'entrenament segons el valor de les seves classes (intenta identificar els atributs que expliquen la major variància entre les classes).
- La idea darrera del LDA és trobar un nou espai de característiques per projectar les dades amb l'objectiu de maximitzar la separabilitat de les classes.